

选题报告：基于生成式推荐的支付界面与购物车互补品推荐算法研究

1. 选题

基于生成式推荐的支付界面与购物车互补品推荐算法研究

核心场景：电商支付页面、购物车页面

技术路线：以深度学习（序列模型、多模态融合、图神经网络）为基础，融合大语言模型（LLM）的生成式推理能力，实现互补商品的端到端推荐与可解释理由生成

目标价值：将支付瞬间从交易终点转化为提升客单价（AOV）与用户满意度的价值起点

2. 背景与痛点（支付界面/购物车场景）

1) 注意力高度集中：支付界面是用户购物旅程中决策能力最集中的环节，购物车已形成明确的购买意图。

2) 传统推荐逻辑失效：此时用户不需要“猜你喜欢”或相似商品推荐（如另一部手机），而是需要场景化智能组合——即与核心商品强互补的配件或搭配品（如手机→手机壳→贴膜→充电宝）。

3) 传统方法的局限：

协同过滤只能发现共现关系，无法理解“为什么需要这个配件”。

单一深度学习模型虽能捕捉购买链，但缺乏可解释性，且难以处理模糊、复杂的用户意图（如“露营”场景下的完整装备清单）。

4) 业务痛点：支付后是提升客单价的关键窗口，但现有推荐常因不相关或不可解释而被用户忽略，错失关联购买机会。

3. 问题定义与目标

3.1 问题定义

给定用户当前购物车/已支付订单中的商品集合（作为核心商品），以及用户的历史行为序列（点击、购买、加购等），如何利用生成式推荐技术，端到端地预测用户最可

能需要的互补商品，并生成自然语言的推荐理由，从而实现“一购多得”的智能搭配。

3.2 项目目标

核心目标：构建一个面向支付/购物车场景的互补品生成式推荐模型，在离线评估中，互补品命中率（HR@10）相比传统序列模型（如 SASRec）提升≥5%。

扩展目标：

模型能输出可解释的推荐理由（如“为您刚入手的专业跑鞋配一双排汗运动袜，提升跑步体验”）。

支持对模糊场景（如“露营”、“海边度假”）的意图解析与需求预判。

业务目标（预期）：在模拟或小规模线上测试中，关联购买率提升 15%以上，客单价（AOV）提升≥10%。

4. 相关工作（传统推荐 vs 生成式推荐）

维度	传统推荐（协同过滤/浅层模型）	生成式推荐（本项目）
核心逻辑	行为匹配：“购买了 A 的人也购买了 B”	意图驱动：“因为您买了 A，所以您可能需要 B（理由：...）”
互补关系挖掘	基于共现频次或简单关联规则（Apriori）	深度序列模型（Transformer）捕捉长时序依赖；图神经网络挖掘隐性搭配规则
可解释性	弱（通常是黑盒）	强：可生成自然语言推荐理由（利用 LLM 提示工程）
场景适配	适用于通用推荐，但对支付场景的“克制感”和“时机”不敏感	可结合强化学习优化实时交互策略（如差 10 元满减时推荐 11 元配件）
技术代表	ItemCF、SVD++、BPR	深度序列模型（RNN/Transformer）、多模态融合

		(ViT+BERT) 、LLM (通义千问、 DeepSeek) 、LLM-PKG 知识图谱、生成式推荐 (TIGER/RecGPT)
--	--	---

本项目定位：在既有协同过滤和内容推荐积累的基础上，针对支付/购物车这一高价值场景，引入生成式推荐范式，实现从“相关性”到“因果性/意图性”的升级。

5. 数据方案

5.1 数据来源

数据集	用途	获取方式	关键字段
阿里移动推荐算法数据集（天池）	基线验证、序列行为建模	天池平台	user_id, item_id, behavior_type(1-4), item_category, time
天猫推荐数据集 Rec-Tmall（天池）	生成式推荐核心训练、理由生成语料	天池平台	Item_id, User_id, Action, Vtime, Title, 用户评论（1122 万条）
Amazon Review Data (Electronics & Clothing)	互补关系挖掘、多模态	https://cseweb.ucsd.edu/~jmcauley/datasets/amazon_v2.html	商品描述、图片、共现信息
H&M Personalized Fashion Recommendations	服饰穿搭互补（从头到脚）	Kaggle	用户购买历史、商品属性（颜色、类别）
Instacart Market Basket Analysis	购物篮共现分析	Kaggle	订单内商品组合
...	...	...	...

5.2 互补品标注方法（无需人工标注，从数据中挖掘）

共现频次法：同一购物篮或用户会话（间隔<1 小时）中，共现次数显著高于随机的商品对 → 候选互补对。

序列关联法：用户行为序列中连续购买对（A→B），时间间隔<7 天且转移概率高 → 互补转移对。

类目规则辅助：利用商品类目树（如“手机 & 手机配件”），预定义部分明确互补关系（如手机→手机壳），作为先验知识。

LLM 辅助挖掘（可选）：利用提示工程让 LLM（如通义千问）离线判断两个商品是否具有互补关系，并生成理由文本（用于训练理由生成模块）。

![img](原始数据

数据清洗

(过滤无效记录、转换时间戳

构造购物篮

构造用户订单时间序列

加载商品类目表

(基于时间窗口/订单 ID)

(按用户和时间排序)

Apriori 算法挖掘共现规则

统计转移对

人工定义互补类目对

(支持度、置信度、提升度)

(A→B,时间间隔<阈值)

(如:手机→手机壳)

合并候选对

是否使用 LLM 校验?

LLM 校验互补关系

并生成推荐理由

输出最终互补品表)

5.3 数据规模预估（基于公开数据集）

用户数：10 万 ~ 100 万（根据所选子集）

商品数：10 万 ~ 800 万

交互记录：百万级 ~ 十亿级

时间跨度：1 个月 ~ 2 年

5.4 数据预处理

- 1、过滤低频用户/商品（交互次数<3）
- 2、按用户 ID 和时间戳排序，构造最大长度 20 的行为序列
- 3、划分训练/验证/测试集（8:1:1）
- 4、对于生成式推荐模型：将商品 ID 离散化为固定长度码本（如每个商品映射为 3 个 token，码本大小 256）

6. 系统架构图

本项目重点关注支付/购物车场景的生成式推荐模块。下图概括了一个决策流程与技术栈分层示例：

![img](刘水霞/8553

数据输入:新请求

交互数据密度判断

刘水霞/8553

"密度=0%"

"0.1%≤密度<1%"

"密度>1%"

召回层:混合召回

召回层:深度学习召回

召回层:基于内容召回

协同过滤为主,内容向量为

序列/GNN 模型+知识图谱

依赖多模态语义向量

辅

路径

精排层:统一精排模型

如需深度理解与文案生成

重排/创意层:LLM 智能体介

直接输出

意图推理、可解释生成

刘水霞/8553

最终推荐列表)

架构说明:

离线层: 预先计算商品内容向量、训练序列模型、利用 LLM 构建可解释互补关系图谱。

在线层: 支付/购物车请求触发多路召回 (包含基于互补图谱的召回), 经精排后, 由生成式模块 (轻量 LLM 或模板+属性填充) 生成推荐理由。

7. 技术方案

7.1 总体技术路线

本项目总体技术路线围绕“离线准备-模型训练-在线推理-评估优化”四大核心阶段展开, 以深度学习与生成式 AI 技术为核心, 贴合支付/购物车场景的高意图、高转化需求, 实现互补品端到端推荐与可解释理由生成, 具体路线如下:

1. 离线数据准备阶段: 基于天池、Kaggle、Amazon 等公开数据集, 完成数据获取、清洗与预处理, 过滤低频用户与商品, 构造用户行为序列及购物篮数据; 通过共现频次法、序列关联法、类目规则辅助及 LLM 离线校验, 挖掘互补商品关系, 生成互补品候选集与伪标签; 同时对商品 ID 进行离散化处理, 构建固定长度码本, 为生成式模型训练奠定数据基础。
2. 基线与核心模型训练阶段: 首先搭建 SASRec 序列模型作为基线, 完成训练与基础评估, 明确传统序列模型的性能基准; 在此基础上, 构建生成式推荐核心模型, 采用 minGPT 轻量级生成模型, 融入 Transformer 架构捕捉用户行为长时序依赖, 结合图神经网络 (GNN) 构建“用户-商品-属性”异构图, 挖掘隐性互补搭配规则; 针对服饰等场景, 引入 ViT 处理商品图像、BERT 处理商品文本, 实现多模态融合, 提升穿搭类互补品推荐的准确性。
3. 可解释性与意图解析模块构建阶段: 利用 LLM (如通义千问、DeepSeek), 通过提示工程设计合理模板, 离线构建互补关系知识图谱 (LLM-PKG) 与推荐理由库, 实现“核心商品→互补商品→推荐理由”的对应映射; 针对模糊场景 (如露营、海边度假), 通过 LLM 意图解析, 将非结构化场景需求转化为结构化商品清单, 提升推荐的场景适配性; 可选引入强化学习, 优化支付界面推荐时机与“克制感”策略, 适配满减等

业务场景。

4. 在线推理与系统整合阶段：结合系统架构设计，搭建离线-在线协同框架，离线预计算商品内容向量、模型参数及推荐理由库，在线接收支付/购物车请求后，根据交互数据密度触发多路召回（混合召回、深度学习召回、基于内容召回），经统一精排模型筛选后，调用生成式模块输出 Top-K 互补商品及对应可解释理由，形成最终推荐列表。

5. 评估与优化阶段：通过离线评估（HR@K、NDCG@K、Complementary Ratio@K 等指标），对比基线模型与生成式模型性能，通过消融分析验证各模块（互补感知注意力、LLM 理由生成等）的贡献；针对模型训练收敛慢、推理延迟高、数据缺少显式标签等问题，采取预训练嵌入初始化、离线理由库查询、多重信号融合构造伪标签等应对策略，持续优化模型性能，最终达成项目核心目标与业务目标。

7.2 关键技术模块？

模块	技术实现
深度序列建模	Transformer（或 SASRec）对用户购买序列建模，学习“手机→手机壳→贴膜”的标准化互补链
多模态融合	ViT 处理商品图像，BERT 处理文本，融合生成内容嵌入，用于服饰“从头到脚”风格匹配
图神经网络（GNN）	构建“用户-商品-属性”异构图，挖掘隐性搭配规则（如小众设计师衬衫与特定版型裤子关联）
强化学习（可选）	在支付界面学习最优推荐时机与“克制感”策略（如差 10 元满减时推荐 11 元配件）
LLM 意图解析	通过提示工程（Prompt Engineering）将“露营”场景解析为结构化需求清单（防

	潮垫、睡袋、炊具等)
LLM 可解释理由生成	利用 LLM（如通义千问、DeepSeek）离线构建互补关系知识图谱（LLM-PKG），在线查询并生成个性化文案
生成式推荐（端到端）	借鉴 TIGER 思想，将商品 ID 离散化为 token，使用轻量 GPT（minGPT）自回归生成下一个商品 ID

7.3 模型选型（本项目中采用）

7.4 训练与推理策略

8. 评估指标设计

8.1 离线评估指标

指标类别	具体指标	说明
推荐准确性	HR@K (K=5,10,20), NDCG@K	标准排名指标，衡量预测下一个互补商品的命中情况
互补特异性	Complementary Ratio@K	推荐结果中属于互补商品（而非替代品或无关品）的比例，需配合人工标注或类目规则验证集
生成质量	BLEU-1/2, ROUGE-L	若实现理由生成，评估生成文本与参考理由的相似度（参考理由可由 LLM 离线生成）

多样性	推荐列表的商品类别覆盖度	避免只推荐同一配件品类
-----	--------------	-------------

8.2 在线/业务指标（模拟或小流量）

关联购买率（Add-on Rate）：推荐商品被一同购买的比例

客单价提升幅度（ ΔAOV ）

推荐理由点击率（如果理由可点击）

用户满意度（可通过问卷或模拟评估）

8.3 评估协议

离线实验：在测试集上计算上述指标，与基线（SASRec、ItemCF）对比。

消融分析：分别移除互补感知注意力、LLM 理由生成等模块，验证各模块贡献。

9. 项目计划（甘特图/时间线）

总时长：6 周

阶段	时间	任务	产出
第一阶段：数据准备	第 1 周	获取并清洗数据集（天池/Amazon），构造互补关系标签，划分训练/验证/测试集	标准化数据集 + 数据报告
第二阶段：基线实现	第 2 周	实现 SASRec 模型，完成训练与基础评估	SASRec 基线模型 + 评估结果
第三阶段：生成式核心模型	第 3 周	实现商品离散化（码本）、minGPT 生成式模型；加入互补感知注意力	生成式推荐模型原型

第四阶段：LLM 理由生成	第 4 周	设计提示模板，利用 LLM（可调用 API 或本地小模型）离线生成互补理由库，在线查询	可解释推荐模块
第五阶段：整合与评估	第 5 周	端到端整合，进行离线评估（与基线对比），消融分析，撰写报告	完整实验报告
第六阶段：PPT 与答辩	第 6 周	制作 PPT，准备演示和答辩	项目 PPT + 讲稿

4 周速成版

周次	周一~周三	周四~周日	里程碑产出
第 1 周	数据获取（天池申请+下载）、数据清洗、序列构造	互补关系标注（共现+类目）、商品离散化、划分数据集	可用的训练/验证/测试集
第 2 周	实现 SASRec 基线，完成训练与基础评估	实现 minGPT 生成式模型（商品 token 序列训练）	SASRec 评估结果 + minGPT 初步模型
第 3 周	minGPT 调优（学习率、层数）、加入互补约束解码	实现理由生成模板、端到端推理脚本	生成式模型完整推理链路
第 4 周	离线评估（对比 SASRec、生成式、生成式+互补约束）、消融分析	整理报告、制作 PPT、准备答辩	项目 PPT + 实验报告

10. 预期成果与创新点

10.1 预期成果

1. 一个可演示的支付/购物车互补品生成式推荐原型系统：输入购物车商品（如手机），输出 Top-3 互补商品（如手机壳、贴膜、充电宝）及推荐理由。
2. 项目文档与 PPT：完整涵盖问题定义、数据、方法、评估、计划。

10.2 创新点

场景聚焦：专门针对支付/购物车这一高转化窗口的互补品推荐，而非通用推荐。

生成式范式应用：将商品离散化+GPT 生成引入互补品发现，实现端到端预测，并天然支持理由生成。

互补感知增强：在生成模型中显式融入互补关系图谱先验，提升推荐相关性。

轻量化可解释：采用离线 LLM 构建理由库+在线检索，避免高延迟，同时提供可读性强的推荐解释。

11. 可行性分析

11.1 数据可行性

公开数据集充足（天池、Amazon、Kaggle），均包含时间戳、商品类别、部分文本描述。

互补关系可通过共现统计和类目规则有效近似，无需人工标注。

11.2 技术可行性

基线 SASRec 有成熟开源实现（RecBole），可快速搭建。

生成式推荐可采用 minGPT（参数量 50M 左右），单卡 GPU（如 RTX 3090）可训练。

LLM 理由生成可调用开源模型（如 Qwen-1.8B）或使用 API（如有预算），亦可采用模板+属性填充的轻量方案。

项目周期 6 周，任务分解合理，可按时完成。

11.3 风险与应对

风险 1：生成式模型训练收敛慢 → 应对：使用预训练 token embedding，从简单序列模型初始化。

风险 2：LLM 推理延迟过高 → 应对：采用离线预生成理由库 + 在线键值查询，不实时

调用大模型。

风险 3：公开数据缺少显式互补标签 → 应对：采用共现+序列+类目规则多重信号融合构造伪标签，并在小规模人工验证集上评估。

风险 4：时间不足 → 应对：放弃部分消融实验，保证主实验完成。

12. Q&A（备选问题与回答要点）

Q1：为什么选择支付/购物车场景而不是首页推荐？

A：该场景用户意图最明确，且是提升客单价的黄金窗口；传统推荐在此处容易推荐替代品（如另一部手机），而生成式推荐能提供互补品和解释，更符合用户真实需求。

Q2：生成式推荐相比传统序列模型（如 SASRec）有什么本质优势？

A：传统序列模型是判别式（预测下一个商品 ID 的概率分布），而生成式模型可以自回归生成，天然支持束搜索、约束解码（强制生成互补品），且容易扩展为输出商品+文本（多任务生成），可解释性更强。

Q3：如何处理新商品（冷启动）在支付场景的推荐？

A：本项目主要针对已有一定交互数据的成熟商品。对于新商品，可复用文档第一部分所述的内容向量冷启动方案（多模态语义匹配），作为生成式模型候选集的一路补充召回。

Q4：评估指标中“互补特异性”如何量化？

A：构建一个验证集，其中包含人工或类目规则标注的“正互补对”和“非互补对”。推荐结果中属于正互补对的比例即为 **Complementary Ratio@K**。若没有标注，可近似用“不同叶子类目且属于同一上层类目（如手机+配件）”的比例代替。

Q5：项目预期能否在课程作业时间内完成？

A：可以。我们选择了数据获取容易、开源代码丰富、计算资源需求适中的技术栈。6 周计划中，前 4 周即可跑通基线+生成式核心模型，后 2 周用于优化和文档整理。

A：我们定位是可行性验证原型，而非工业级系统。通过复用开源模型、简化互补约束、使用轻量级 GPT，可以在 4 周内完成从数据到离线评估的全流程。

Q6：为什么不直接用大语言模型（如通义千问）？

A：大模型推理延迟高、资源需求大，不适合此作业。我们采用商品离散化+小 GPT 的方式，既体现生成式思想，又能在普通 GPU 上运行。

Q7：项目最大的创新点在哪里？

A：在有限资源下，将生成式推荐范式（离散化+自回归生成）首次应用于电商互补品场景，并设计了零成本的互补约束解码策略，使得小模型也能产出高互补性的推荐。

| (注：文档部分内容可能由 AI 生成)